

다중 환경 오프라인 강화학습 비교 연구

Ray RLlib 기반 3가지 환경별 구현 사례



컴퓨터공학과 김만종, 김지훈, 최은기

👤 김만종: HALFCHEETAH 오프라인 RL 비교 연구

🧪 실험 개요

환경: HalfCheetah-v5 (MuJoCo)

전문가 모델: PPO로 학습 (~3,800점)

데이터셋:

- ▶ Small: 50 episodes
- ▶ Large: 500 episodes

비교 알고리즘:

- ▶ **BC**: Behavior Cloning (단순 모방)
- ▶ **CQL**: Conservative Q-Learning
- ▶ **MARWIL**: Advantage 기반 학습


💡 핵심 발견

10x

데이터 양 증가 시 성능 향상

- ▶ 데이터 양이 결정적: 50 Ep → 1,500점, 500 Ep → 3,400점
- ▶ **MARWIL** 우수성: 가장 빠른 수렴 & 최고 성능 (3,400+점)
- ▶ **CQL** 실패: 소량 데이터(50 Ep)에서 학습 붕괴
- ▶ **Learning Rate**: $1e-4$ 가 $5e-5$ 보다 빠른 수렴


김만중: 실험 결과 시각화




데이터 양에 따른 성능 차이 (50 vs 500 Ep)



알고리즘 비교 (BC vs CQL vs MARWL)



MARWL 하이퍼파라미터 비교 (LR 1e-4 vs 5e-5)



전체 실험 성능 종합 비교

★ 최종 권장: MARWL (beta=1.0, lr=1e-4) + 500 Ep 이상 데이터 → 전문가 대비 89% 성능 달성

김지훈: HALFCHEETAH EXPERT POLICY 학습

🗺️ 12단계 실험 여정

Phase 1: 대규모 네트워크 (실패)

- ▶ Network: [1024, 1024], Batch: 8192
- ▶ 결과: 1260점 Plateau (Local Optima 고착)

Phase 2: 탐색 강화 (불안정)

- ▶ Entropy Scheduling, KL Penalty 제거
- ▶ 결과: 정체 탈출했으나 변동성 증가

Phase 3: SOTA 설정 (성공) Best

- ▶ Network: [512, 256] / [256, 256]
- ▶ Batch: 65536, Epochs: 32
- ▶ 결과: 최고 3073점, 안정 2700점

🔍 핵심 통찰

2.4x

Phase 1 대비 최종 성능 향상

- ▶ **Network Size:** 작은 네트워크가 오히려 안정적 (과적합 방지)
- ▶ **Batch & Epochs:** 큰 배치(65K) + 충분한 반복(32)이 핵심
- ▶ **Exploration:** 무분별한 탐색보다 안정적 수렴이 중요
- ▶ **시행착오:** 12번의 실험을 통해 최적 설정 도출


Google Brain 권장 설정으로 회귀한 것이 성공 요인

김지훈: 학습 곡선 분석

HalfCheetah-v5 Expert Training: Phase Comparison




12 Experiments: Failure to Success Journey




12개 실험의 점진적 성능 향상 과정

Architecture Impact



Training Stability



2.4x

Phase 1 대비 성능 향상

핵심 성공 요인:

- ▶ 큰 배치(65K) + 충분한 반복(32)
- ▶ 작은 네트워크가 안정적
- ▶ 12단계 시행착오 학습

👤 최은기: ATARI BREAKOUT BC/IQL 학습

🎮 실험 개요

환경: ALE/Breakout-v5 (시각 입력)

실험 카테고리:

1. BC Augmentation

- ▶ Baseline (No Aug)
- ▶ Shift Augmentation
- ▶ Noise Augmentation
- ▶ All Augmentations

2. IQL Hyperparameter Tuning

- ▶ Beta: 10, 15, 20
- ▶ Tau: 0.7 (default), 0.8 (tuned)

3. Advanced Techniques

- ▶ Label Smoothing, Mixup, Large Batch
- ▶ OneCycle LR, Combined

🏆 주요 성과

195

최고 Reward (BC + All Aug)

- ▶ **Data Augmentation 효과:** Baseline 160 → All Aug 195 (22% ↑)
- ▶ **IQL Best Config:** Beta=10, Tau=0.8 (180점)
- ▶ **시각 환경 도전:** 고차원 입력으로 학습 불안정성 증가
- ▶ **Sample Efficiency:** BC가 IQL/CQL보다 빠른 수렴


시각 환경에서는 **Data Augmentation**이 필수적

🚀 최은기: ATARI 실험 결과


Atari BC: Data Augmentation Impact on Performance



Atari IQL: Hyperparameter Tuning (Beta & Tau)



Atari Breakout: Offline RL Algorithm Comparison



📊 전체 알고리즘 성능 & 효율성 비교

22%

Augmentation 성능 향상

핵심 결론:

- ▶ BC + Augmentation 최적
- ▶ 시각 환경 특화 필수
- ▶ Sample Efficiency 우수

종합 결론 및 시사점

김만중

3,400

HalfCheetah 최고 점수

- ▶ **MARWIL** 알고리즘 우수
- ▶ 데이터 양이 결정적 요인
- ▶ 전문가 대비 89% 달성

김지훈

2.4x

Phase 1 대비 성능 향상

- ▶ 12단계 시행착오 과정
- ▶ 큰 배치 + 충분한 반복
- ▶ 작은 네트워크가 안정적

최은기

22%

Augmentation 효과

- ▶ 시각 환경 특화 연구
- ▶ Data Augmentation 필수
- ▶ BC가 가장 효율적

핵심 교훈 및 향후 방향

오프라인 강화학습 성공 요인

- ▶ 데이터 품질 > 알고리즘: 충분한 양의 고품질 전문가 데이터가 필수
- ▶ 환경별 최적화: MuJoCo는 MARWIL, Atari는 BC + Augmentation
- ▶ 하이퍼파라미터 튜닝: 체계적 실험을 통한 최적 설정 도출
- ▶ 안정성 우선: 과도한 탐색보다 안정적 수렴이 중요

향후 연구 방향

- ▶ 온라인 **Fine-tuning**: 오프라인 사전학습 후 온라인 개선
- ▶ **Model-based RL**: 샘플 효율성 극대화
- ▶ **Multi-task Learning**: 여러 환경에서 일반화
- ▶ **Real-world 적용**: 로봇공학, 자율주행 등